

Mental Aktivitelere ilişkin EEG Kayıtlarının Hjorth Parametreleri ile Sınıflandırılması

Classification of Mental Task EEG Records Using Hjorth Parameters

Ömer TÜRK	Mesut Şeker	Veysi AKPOLAT	Mehmet Sıraç ÖZERDEM
Midyat Meslek Yüksekokulu	Elektrik-Elektronik Mühendisliği	Tıp Fakültesi	Elektrik-Elektronik Mühendisliği
Mardin Artuklu Üniversitesi	Dicle Üniversitesi	Dicle Üniversitesi	Dicle Üniversitesi
Mardin, Türkiye	Diyarbakır, Türkiye	Diyarbakır, Türkiye	Diyarbakır, Türkiye
omerturk@artuklu.edu.tr	mesut.seker@dicle.edu.tr	vakpolat@dicle.edu.tr	sozerdem@dicle.edu.tr

Özetçe — Mental aktivitelerin beyin dinamiği üzerindeki etkisi, uzun süre çalışılan bir konu olmakla birlikte, henüz istenilen düzeye ulaşamamıştır. Bu çalışmada da çeşitli mental aktivitelere ilişkin EEG kayıtlarının Hjorth parametreleri ile sınıflandırılması amaçlanmıştır. Çalışmada kullanılan EEG kaydı, 9 katılımcıdan alınmıştır. Katılımcılara 5 farklı mental görev içeren görsel uyarılar gösterilmiş ve akabinde çeşitli aktiviteler yapmaları istenmiştir. Bu uyarılar ile istenen aktiviteler; zihinden kelime birleştirme, zihinden çıkarma işlemi, konumsal takip, sağ el hareketi ve ayak hareketi şeklindedir. Elde edilen bu veri setine dalgacık paket dönüşümü uygulanarak alt bantlarına ayrıştırılmıştır. Bu ayrıştırma sonucu oluşan her alt bantın; Hjorth parametrelerinden hareketlilik, karmaşıklık ve kendi aralarında Mahalanobis uzaklıklarının istatistiksel değerleri elde edilerek, öznitelik vektörü oluşturulmuştur. Elde edilen öznitelikler yapay sinir ağı ile sınıflandırılmıştır. Mental aktivitelerin sınıflandırma performansları incelendiğinde “zihinden kelime birleştirme – zihinsel çıkarma işlemi”, “konumsal takip-ayak hareketi” ve “konumsal takip – zihinden kelime birleştirme” uyarıları arasında yüksek sınıflandırma performansı (yaklaşık %80) olduğu görülmüştür. En düşük performans ise “zihinden kelime birleştirme - sağ el hareketi”, “zihinsel çıkarma işlemi - sağ el hareketi”, “konumsal takip - sağ el hareketi” arasında elde edilmiştir. Tüm uyarıların kendi aralarında sınıflandırma performansı ise %77,61 olarak bulunmuştur.

Anahtar Kelimeler — Dalgacık Paket Dönüşümü, Hjorth Parametreleri, Mental Aktivite

Abstract — The effects of mental activities on brain dynamics is the main field that studied for a long time, but the results of studies have not reached the desired level. The aim of present study was to classify the mental task EEG records by using Hjorth parameters. In this study, EEG signals that recorded from 9 subjects were used. EEG signals were recorded by applying a experimental paradigm which contains five stimuli related to different mental task. These stimuli are defined as condition word mental subtraction spatial navigation right hand motor imagery and feet motor imagery Wavelet packet transform was used to obtain sub-bands of EEG signals. Statistical parameters that consist of mobility, complexity and Mahalanobis distance were applied to sub-bands. Feature vectors were classified by using

artificial neural network. When classification performances related to mental activities were examined, the best classification accuracy was obtained as nearly 80% for ‘condition word - mental subtraction’, (‘spatial navigation - feet motor imagery,’ and ‘spatial navigation - condition word’. The lowest classification accuracy was obtained for ‘mental subtraction - right hand motor imagery,’ ‘condition word - right hand motor imagery’ and ‘spatial navigation - right hand motor imagery’. The classification accuracies related to all stimuli that classified among themselves were obtained as 77,61%.

Keywords — Wavelet Packet Decomposition, Hjorth Parameters, Mental Task

I. GİRİŞ

Elektroensefalogram (EEG), beyin fonksiyonel ve mental aktivitesi ile ilgili elektriksel aktiviteleri ifade eder [1-2]. EEG kapsamındaki spektral değişim, farklı frekans bantlarına göre değerlendirilir. Bu bantlar: delta (δ , 0.5-4Hz), teta (θ , 4-8Hz) alfa (α , 8-13Hz), beta (β , 15-30Hz) ve gama (γ , 30-üstü Hz) bantlarıdır [3].

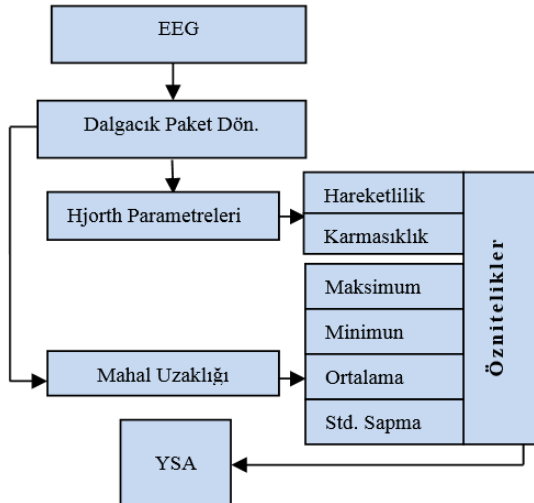
EEG kayıtlarının sınıflandırılmasında genellikle izlenen yol, üç aşamadan oluşmaktadır. Bu aşamalar; i) EEG kaydının alınması ve artifaktlardan arındırılarak işlenebilir forma getirilmesi, ii) özniteliklerin çıkartılması, iii) sınıflandırıcılar ile özniteliklerin sınıflandırılmasıdır. Analizler için açık veri tabanlarında verilen EEG kayıtları, çoğunlukla artifaktlardan arındırılmış formdadır. Dolayısıyla sözü edilen üç aşamadan ilki için herhangi bir işlem yapılmaz. Kalan iki aşama için literatürde birçok çalışmanın olduğu görülmektedir. Bu aşamalar için EEG analizi ile ilişkili yapılan temel araştırmalardan bazıları; EEG kayıtlarından sağ ve sol el hareketlerinin sınıflandırılması için yapay sinir ağı (YSA) kullanımı [4], Gauss dağılımı ile mental aktivitelerin sınıflandırılması için Bayesian YSA kullanımı [5], sağ el ve ayak işaretlerinin görgül kip ayrışımı, ayrı dalgacık dönüşümü (ADD) ve dalgacık paket dönüşümü (DPD) kullanılarak dalgacık katsayılarının ortalaması, güç ortalaması ve standart sapması ile elde edilen özniteliklerin destek vektör makinesi (DVM) ile sınıflandırılmasıdır [6].

Ayrıca, normal ve hastalıklı EEG'nin tespiti için lineer olmayan Dalgacık Entropi, Örnek Entropi ve Spektral Entropi öznitelikleri hesaplanarak YSA ile sınıflandırılması [7], epilepsi tespiti için DD ile bantlara ayrıştırılan EEG bölütlerinden, Mahalanobis metrik bilgisi ve Örnek Entropi özniteliklerinin çıkartılarak sınıflandırılması [8], epilepsi tespiti için EEG veri setinin bölütlerine pencere uygulanarak optimal örnek ayırma yönteminin uygulanması, elde edilen özelliklerin boyutlarının azaltılması (Temel Bileşen Analizi (TBA) ve Doğrusal Ayırma Analizi (DAA) ve sınıflandırıcılar (DVM, Naive Bayes, k-NN) ile ayrıştırılması [9] gibi temel çalışmalar literatürde görülebilmektedir. Özellikle literatürde bu çalışma kapsamında kullanılan veri setini kullanan bir çalışmada, Lineer Diskriminant Analizi (LDA) kullanılarak her zihinsel görev çiftlerinin farklı gün için farklı ayrıştırılabilirliği değerlendirilmiştir. Katılımcıların gerçek pozitif oran ile gerçek negatif oran değerleri %43-94 aralığında bulunmuştur. Tüm katılımcılar için bu değerlerin medyanı %68-82 aralığında elde edilmiştir [10]. Bu çalışmada ise mental aktivitelerine ilişkin EEG kayıtları Hjorth parametreleri ile sınıflandırılmıştır.

II. MATERYAL VE YÖNTEM

A. Önerilen Sınıflandırmaya Ait İşlem Akışı

Bu çalışmada EEG kayıtlarının frekans bantlarına ayrışımı için DPD yöntemi kullanılmış, özniteliklerin oluşturulması için Hjorth parametreleri ile Mahalanobis uzaklığından elde edilen istatistiksel veriler kullanılmıştır. Bu çalışmada önerilen sınıflandırmaya ait işlem akışı Şekil 1'de gösterilmiştir. Çalışmada EEG kayıtlarından her bir mental görev için 24 adet öznitelik vektörü elde edilmiştir.



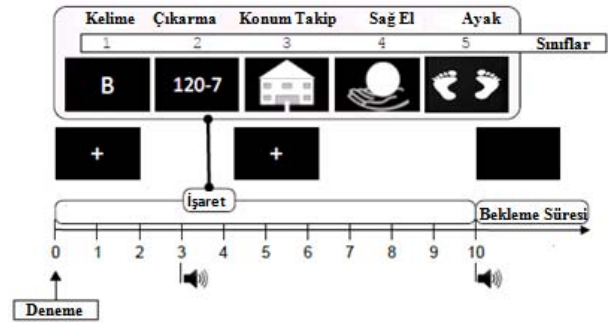
Şekil 1 Bu Çalışmada Önerilen İşlem Akışı

Bu çalışmada, kullanılan EEG işareti her bir uyarı için uyarının gösterildiği 3-4.25 saniye aralığı alınarak elde

edilmiştir. Elde edilen EEG verisinin DPD kullanılarak teta, alfa, beta ve gama alt bandlarının paket dalgacıkları elde edilmiştir. Her alt band DPD katsayılarının, Hjorth parametrelerinden hareketlilik ve karmaşıklık ile teta-alfa, alfa-beta, beta-gama, ve gama-teta alt bandlarının Mahalanobis uzaklıkları bulunarak bu uzaklığa ait istatistiksel sonuçlar öznitelik vektörü olarak kullanılmıştır. Çalışmada sınıflandırma işlemi için en iyi performansın elde edildiği öznitelik kümesi kullanılmıştır. Bu öznitelikler çok katmanlı yapay sinir ağına verilerek sınıflandırılmıştır.

B. Veri Seti

Bu çalışma kapsamında kullanılan EEG verisi, BNCI Horizon 2020 projesi web sitesinden temin edilmiştir [11]. EEG verisi 2 farklı günde 9 rahatsız kişiden (omurilik zedelenmesi) kaydedilmiştir. 5 farklı mental görev içeren uyarı gösterilmesi ile istenenin yapıldığı bir deney paradigması mevcuttur. Bu uyarılar zihinden kelime birleştirme, zihinden çıkarma işlemi, konumsal takip, sağ el ve ayak hareketi hayali şeklindedir. Bir gün içinde her kişiye ait uygulama her bir sınıf için 40 deneme alınıp bu işlem 8 defa tekrarlanmıştır. Bu 8 tekrardan her biri her sınıfa ait 5 uyarı olmak üzere toplam 25 adet uyarı bulunmaktadır. Uyarılar rastgele gösterilmiştir. EEG verileri 10-20 elektrot sistemine göre dizilmiş 30 elektrottan alınmıştır. Kullanılan EEG verileri 0.5-100 Hz band geçiren filtreden geçirilmiş ve 256 Hz örnekleme frekansına sahiptir. Çalışmada kullanılan EEG kaydının paradigması (şekil 2):



Şekil 2 DeneySEL Paradigma

Her bir deneme süresi 10 saniyedir. t=0 anında ekranın ortasında bir çarpı işareti gösterilmiştir. Katılımcıya rahatlaması ve gözünü ekrandan ayırmaması söylenmiştir. t=3 anında bir bip sesi ile katılımcı uyarılmıştır. t=3 ile t=4.25 arasında verilen işarete göre 5 uyarı hareketinden biri yaptırılmıştır. t=10 anında ekranın ortasındaki işaret kaybolup bip sesi ile hareket sona erdirilmiştir. Diğer bir deneme yapılmadan önce 2.5-3.5 saniye civarı bir ara verilmiştir. Katılımcıdan işlemler süresince hareket

etmemesi ve gözünü kırpmaması istenmiştir. Her deneme arasında 4 saniyelik boş ekran konulmuştur.

C. Dalgacık Paket Dönüşümü (DPD)

Dalgacık dönüşümü (DD) işaretin frekans içeriğinin zamanla değişimini incelemek amacıyla dalgacık fonksiyonu ile birlikte farklı ölçek (scale) ve kaydırma (shift) değerleri kullanır [12]. Sürekli Dalgacık Dönüşümü (SDD) ayrıştırma işlemi:

$$DD(a, u) = \frac{1}{\sqrt{|a|}} \int_{-\infty}^{+\infty} x(t) \psi\left(\frac{t-u}{a}\right) dt \quad (1)$$

Burada $x(t)$ işareti, $DD(a, u)$ dalgacık dönüşümü, ψ ana dalgacık fonksiyonu, a ölçek ve u kaydırma parametresini ifade eder. SDD 'de bütün ölçeklerde hesaplanan dalgacık katsayıları çok büyük veri yığını oluşmasına neden olur. [13-14]. SDD fonksiyonunun temel özelliklerini temsil eden bazı örnekler seçilirse, ayrık dalgacık dönüşümü elde edilmiş olur. Sürekli dalgacık formülünde ölçek ve kaydırma parametreleri sırasıyla $a = 2^m$ ve $u = n.2^m = n.a$ olarak alınır ve elde edilen Ayrık Dalgacık Dönüşüm (ADD) bağıntısı:

$$D(j, k) = \sum_j \sum_k x(n) 2^{-m/2} \psi(2^{-m}n - k) \quad (2)$$

Bu işlemde kullanılan filtrelerin matematiksel ifadeleri (3) ve (4) eşitliklerinde verilmiştir.

$$g(k) = \sum_n x(t)g(2k - t) \quad (3)$$

$$h(k) = \sum_n x(t)h(2k - t) \quad (4)$$

Dalgacık paket dönüşümü ise dalgacık dönüşümünün daha detaylı ve esnek işaret işleme olanağı tanıyan genel bir formdur. Ayrık dalgacık dönüşümünde her adım, bir önceki yaklaşım katsayılarının yüksek ve alçak geçiren filtrelerden geçirilmesi ile hesaplanırken, dalgacık paket dönüşümünde hem detay hem de yaklaşım katsayıları kullanılmaktadır. Çalışmada dalgacık paket dönüşümü için daubechies dalgacık ailesinden 'db4' dalgacığı kullanılmış ve 6. Seviye kadar ayrıştırma yapılmıştır.

TABLO I. EEG FREKANS BANTLARI VE DPD KATSAYILARI

EEG Bantları	Frekans Aralıkları (Hz)	Bantlar için Kullanılan Dalgacık Paket Katsayıları
Teta	6-8 Hz	C[6,3]
Alfa	10-16 Hz	C[6,5]+C[6,6]+C[6,7]
Beta	16-28 Hz	C[5,4]+C[5,5]+C[5,6]+C[5,7]
Gama	32-48 Hz	C[4,4]+C[4,5]

III. ÖZNİTELİKLERİN ELDE EDİLMESİ

A. Hjorth Parametreleri

Çalışmada öznitelik elde etmek için Hjorth parametrelerinden hareketlilik (M-mobility) ve karmaşıklık (C-complexcity) kullanılmıştır. Hareketlilik parametresi, sinyalin birinci türevinin varyansı ile sinyalin varyansının oranının karekökü olarak tanımlanır (5). Karmaşıklık ise işaretin band genişliğinin kestirimi olarak tanımlanabilir [15] (6). Hareketlilik parametresi;

$$M = \sqrt{\frac{var(y'(t))}{var(y(t))}} \quad (5)$$

Karmaşıklık parametresi;

$$C = \frac{M(y'(t))}{M(y(t))} \quad (6)$$

ile hesaplanır.

Çalışmada teta, alfa, beta ve gama alt bandlarının Hjorth parametrelerinden hareketlilik ve karmaşıklık değerleri hesaplanmıştır.

B. Mahalanobis Uzaklığı

Mahalanobis uzaklığı çok değişkenli veri üzerinden hesaplanır. x , p boyutlu gözlemlerden oluşan veri matrisi, \bar{x} , veriden hesaplanan ortalama vektörü ve S aynı veriden hesaplanan örneklem varyans-kovaryans matrisi olmak üzere Mahalanobis uzaklığı:

$$Mah = \sqrt{(x - \bar{x}) S^{-1} (x - \bar{x})} \quad (7)$$


formülü ile hesaplanır. Mahal = mahal (Y, X), X'deki referans örnekten Y'deki her gözlemin Mahalanobis mesafesini (kareli birimler halinde) hesaplar.

Çalışmada teta-alfa, alfa-beta, beta-gama, ve gama-teta alt bandlarının Mahalanobis uzaklıkları bulunarak bu uzaklıklara ait maksimum, minimum, ortalama ve standart sapma değerleri hesaplanmıştır.

C. Çok Katmanlı Yapay Sinir Ağları (ÇKYSA)

ÇKYSA ağlarda nöronlar katmanlar şeklinde organize edilmiştir. ÇKYSA bir giriş katmanı, bir veya birden fazla gizli katman ve bir çıkış katmanından oluşur. Giriş katmanı, bilgilerin ÇKYSA'ya alınmasını sağlar. Çıkış katmanı, bilginin dışarıya iletildiği katmandır. Şekil 3'te ÇKYSA yapısı gösterilmektedir. Çalışmada kullanılan yapay sinir ağının 2 çıkışı ve gizli katmanında 25 nöronu bulunmaktadır. Çalışmada her bir sınıf için 40 deneme olmak üzere, bir katılımcı için toplam 200 deneme bulunmaktadır. Bir katılımcı için toplam 200 deneme ve otuz kanal olmak üzere toplamda 200x30x5 (deneme

sayısı x kanal sayısı x mental görev) veri seti elde edilmiştir. Elde edilen her bir veri setinin 3/4' ü eğitim için, 1/4' ü de test için kullanılmıştır.



Şekil 3 Çok Katmanlı YSA

IV. BULGULAR VE TARTIŞMA

Çalışmada elde edilen sınıflandırma sonuçları Tablo 2’de gösterilmiştir.

TABLO II. UYARTILARIN SINIFLANDIRMA PERFORMANSI

Uyartı	Denek									
	A	C	D	E	F	G	H	J	L	Ort.
1-2	81.25	90.00	98.75	86.25	51.25	71.25	90.00	66.25	85.00	80.00
1-3	81.25	93.75	91.25	86.25	52.50	83.75	91.25	67.50	73.75	80.14
1-4	62.50	87.50	95.00	96.25	50.00	81.25	70.00	65.00	56.25	73.75
1-5	68.75	90.00	77.50	83.75	80.00	80.00	68.75	71.25	87.50	78.61
2-3	81.25	83.75	66.25	95.00	70.00	80.00	67.50	72.50	95.00	79.03
2-4	62.50	93.75	75.00	76.25	50.00	86.25	78.75	70.00	70.00	73.61
2-5	68.75	93.75	90.00	95.00	70.00	90.00	68.75	65.00	63.75	78.33
3-4	62.50	98.75	66.25	90.00	62.55	86.25	75.00	56.25	67.50	73.89
3-5	75.00	93.75	75.00	82.50	67.50	98.75	77.5	72.50	85.00	80.83
4-5	75.00	76.25	88.75	88.75	73.75	85.00	75.00	68.75	70.00	77.92
Ort.	71.88	90.13	82.38	88.00	62.76	84.25	76.25	67.50	75.38	77.61
Medyan	71.87	91.87	83.12	87.50	65.025	84.37	75.00	68.15	71.87	

Tablo incelendiğinde en yüksek performansın “zihinden kelime birleştirme - zihinsel çıkarma işlemi”, “konumsal takip- ayak hareketi” ve “konumsal takip- sağ el hareketi” uyartılarında %98,75 olarak bulunmuştur. Tüm uyartıların sınıflandırma performansları incelendiğinde “zihinden kelime birleştirme - zihinsel çıkarma işlemi”, “konumsal takip – ayak hareketi” ve “konumsal takip - zihinden kelime birleştirme” uyartıları arasında yüksek sınıflandırma performansı (yaklaşık %80) olduğu görülmüştür. En düşük performansın ise “zihinden kelime birleştirme- sağ el hareketi”, “zihinsel çıkarma işlemi- sağ el hareketi”, “konumsal takip - sağ el hareketi” arasında elde edilmiştir. Katılımcılar arasında; en düşük performansın F katılımcısında, en yüksek performansın ise C katılımcısında olduğu görülmüştür. Genel olarak en düşük performansın sağ el hareketi, en yüksek performansın ise konum takip kombinasyonlarında olduğu görülmüştür. Tüm uyartıların kendi aralarında sınıflandırma performansı %77,61 olarak bulunmuştur. Literatürdeki [10] çalışma ile kıyaslandığında, çalışmamızın başarı performansının yaklaşık %7, tüm

katılımcıların sınıflandırma performansının medyan değerlerinde ise yaklaşık %10 arttığı görülmüştür.

V. SONUÇ

Bu çalışmada, merkezi sinir sisteminde doku hasarı (inme ya da omurilik hasarı) bulunan katılımcılara ilişkin zihinsel EEG verilerinin sınıflandırılması gerçekleştirilmiştir. Çalışmada katılımcılara 5 farklı mental görev içeren uyartı gösterilmiş ve her uyartıya karşılık bir işlevin gerçekleşmesi istenmiştir. Bu paradigmadaki kayda alınan mental EEG verileri ikili olarak sınıflandırılmıştır. Sınıflandırmada, mental aktivitelerin kendi aralarında sınıflandırma performansı karşılaştırılmıştır. Ayrıca mental aktivitelerin tüm katılımcılardaki performansları da bulunmuştur. Tüm katılımcılar için ortalama olarak sınıflandırma başarımının %73,61-80,83 aralığında olduğu gözlemlenmiştir.

KAYNAKÇA

- [1] Adeli, H., Zhou, Z. and Dadmehr N., “Analysis of EEG records in an epileptic patient using wavelet transform”, *Journal of Neuroscience Methods*, Vol 123, Iss 1, pp. 69-87, 2003.
- [2] Sharma, R. and Pachori, R. B., “Classification of epileptic seizures in EEG signals based on phase space representation of intrinsic mode functions”, *Expert Systems with Applications* 42, 1106–1117, 2015.
- [3] Crespel, A., Gélisse, P., Bureau M. and Genton, P., “Atlas of Electroencephalography”, *Third ed., J Libbey Eurotext, Paris*, 2006
- [4] Zhichuan T., Chao L., Shouqian S., “Single-trial EEG classification of motor imagery using deep convolutional neural networks”, *Optik*, 130, 11–18, 2017
- [5] He L., Liu B., Hu D., Wen Y., Wan M., Long J., “Motor imagery EEG signals analysis based on Bayesian network with Gaussian distribution”, *Neurocomputing*, 188, 217–224, 2016
- [6] Kevric A. J., Subasi A., “Comparison of signal decomposition methods in classification of EEG signals for motor-imagery BCI system”, *Biomedical Signal Processing and Control*, 31, 398–406, 2017
- [7] Bridwell, D. A., Wu, L., Eichele, T. and Calhoun, V. D., “The spatio-spectral characterization of brain networks: using concurrent EEG spectra and fMRI maps” *Neuro Image* 69, 101–111, 2013.
- [8] Basar, E., and Guntekin, B., “Review of delta, theta, alpha, beta, and gamma response oscillations in neuropsychiatric disorders”, *Application of Brain Oscillations in Neuropsychiatric Diseases (Supplements to Clinical Neurophysiology)*, Vol. 62, 2013
- [9] Basar, E., Basar-Eroglu, C., Karakas, S. and Schürmann, M., “Gamma, alpha, delta, and theta oscillations govern cognitive processes”, *International Journal of Psychophysiology*, 39 241, 248, 2001.
- [10] Scherer, R., Faller, J., Friedrich, E. V., Opisso, E., Costa, U., Kübler, A., & Müller-Putz, G. R., “Individually adapted imagery improves brain-computer interface performance in end-users with disability”, *PLoS one*, 10(5), e0123727, 2015
- [11] <http://bnci-horizon-2020.eu/database/data-sets>
- [12] Xu Q., Zhou H., Wang Y., Huang J., “Fuzzy support vector machine for classification of EEG signals using wavelet-based features”, *Medical Engineering & Physics*, 858-865 -2009.
- [13] Hamid M., Mobarakeh S. Z., “Improvement of EEG-based motor imagery classification using ring topology-based particle swarm optimization”, *Biomedical Signal Processing and Control*-32, 69-75, 2017
- [14] Hea Ka., Wanga L., Zoua Y., Lai K. K., “School Value at risk estimation with entropy-based wavelet analysis in exchange markets”, *Physica A* 408 (2014) 62–71
- [15] Cecchin T., Ranta R., Koessler L., Caspary O., Vespignani H., Maillard L., “Seizure lateralization in scalp EEG using Hjorth parameters”, *Clinical Neurophysiology*, 121, 290–300, 2010